

UNIVERSIDAD DE BUENOS AIRES
LABORATORIO DE SISTEMAS EMBEBIDOS
ESPECIALIZACIÓN EN INTELIGENCIA ARTIFICIAL
PROBABILIDAD Y ESTADÍSTICA PARA LA INTELIGENCIA ARTIFICIAL

EXAMEN FINAL - INFORME

Nombre: Matías Agustín Souto

Código CEIA: a2638

1. PLANTEAMIENTO DE LOS PROBLEMAS DE INVESTIGACIÓN

Don Francisco cuenta hoy con 5 supermercados ('Santa Ana', 'La Floresta', 'Los Cedros', 'Palermo' y 'Córdoba') y plantea dos inquietudes:

- (a) Entender mejor la afluencia mensual de clientes del supermercado 'Santa Ana'.
- (b) Determinar si la afluencia de clientes es la misma en las cinco tiendas, o si alguna se comporta de forma distinta y requiere más atención por recibir menos clientes que las demás.

A partir de estas dos inquietudes se solicita resolver cuatro problemas:

1. Simular el número de clientes diarios de cada tienda entre 2023 y 2025, mediante un modelo Poisson cuyo parámetro λ depende aditivamente del año, el mes, el día de la semana y la tienda.
2. Construir intervalos de confianza para la afluencia mensual de 'Santa Ana', a los niveles de significancia del 95% y del 99%.
3. Determinar, mediante un ANOVA, si el número esperado de clientes es igual en las cinco tiendas o si existen diferencias significativas entre ellas.
4. Identificar la tienda con mayor y con menor promedio de clientes, y contrastar si la diferencia entre ambas es estadísticamente distinta de cero, verificando si coinciden con las tiendas de mayor y menor efecto teórico definido en el enunciado.

2. PROCESAMIENTO REALIZADO A LOS DATOS

2.1 Simulación (Punto 1)

Se construyó una grilla con el producto cartesiano de las 1096 fechas (2023-01-01 a 2025-12-31) por las 5 tiendas, resultando en 5480 filas. Para cada fila se calculó:

$$\lambda(t, s) = \text{efecto_año}(t) + \text{efecto_mes}(t) + \text{efecto_día_semana}(t) + \text{efecto_tienda}(s)$$

usando las tablas de efectos provistas en el enunciado. Sobre ese λ se generó una realización de clientes diarios mediante muestreo Poisson (`numpy.random.default_rng` y semilla fija para reproductibilidad).

Se verificó la integridad de los datos generados:

- Dimensión esperada: $1096 \times 5 = 5480$ filas (verificado).
- Sin valores nulos tras los merges de efectos (verificado).

- Rango de lambda: mínimo 4000 (Palermo, domingo de enero/diciembre 2023) y máximo 13500 (Santa Ana, miércoles de julio 2025) (verificado).

Los datos consolidados se guardaron en `./data/consolidated.csv`.

2.2 Intervalos de confianza para 'Santa Ana' (Punto 2)

Para cada uno de los 12 meses calendario se filtraron los registros de 'Santa Ana' (entre 85 y 93 observaciones por mes, según el mes y los 3 años de datos) y se calculó la media y el desvío estándar muestral de los clientes diarios.

El intervalo de confianza se construyó con el estadístico z:

$$IC(1-\alpha) = \text{media} \pm z(1-\alpha/2) * \sigma$$

donde sigma se estimó con el desvío estándar muestral. Esta aproximación normal es válida porque una Poisson(lambda) es la suma de lambda variables Poisson(1) independientes e idénticamente distribuidas y por el Teorema Central del Límite, para lambda grande, Poisson(lambda) se aproxima por una Normal(lambda, lambda). Los lambda diarios de 'Santa Ana' varían entre alrededor de 8000 y 11500, todos suficientemente grandes para sostener esta aproximación. Se usaron $z(0.975)=1.96$ para el 95% y $z(0.995)=2.576$ para el 99%.

2.3 ANOVA entre tiendas (Punto 3)

Se planteó un ANOVA de un factor (la tienda) con 5 grupos de 1096 observaciones cada uno.

Antes de interpretar el resultado del test se verificaron sus supuestos de independencia, normalidad y homocedasticidad:

- Independencia: se cumple por construcción, ya que cada observación de clientes se generó mediante un muestreo Poisson independiente.
- Normalidad: sostenida por el mismo argumento del Punto 2 (Poisson con lambda grande se aproxima a una Normal).
- Homocedasticidad: se verificó con el test de Bartlett

El ANOVA en sí se calculó con `scipy.stats.f_oneway`, y la decisión se tomó exclusivamente en base al p-valor obtenido, contra el nivel de significancia $\alpha=0.05$.

2.4 Contraste entre tienda de mayor y menor promedio (Punto 4)

Se identificaron la tienda de mayor y de menor promedio de clientes observado, y se aplicó un contraste z de dos muestras independientes ($n=1096$ por tienda), bajo el mismo argumento de aproximación normal ya utilizado. Se verificó además la tienda observada contra la de mayor y menor efecto teórico definido en las tablas del enunciado.

3. RESULTADOS ENCONTRADOS

3.1 Simulación (Punto 1)

Este punto implicaba juntar todas las partes y aplicar el método poisson del generador de numeros aleatorios de numpy. Se sumaron todos los lambdas y los promedios de clientes diarios simulados por tienda fueron:

Santa Ana	10716.5
Los Cedros	8717.1
Córdoba	8714.9
La Floresta	7712.9
Palermo	6718.3

El desafío fue más computacional que estadístico porque hubo que combinar diferentes tipos de valores en una misma ecuación. Para eso vino a bien el uso de pandas, ya que puede relacionar el día con un número (lunes = 0, ... domingo=6) via el atributo dt de la Series que representan los días. Como esa key se necesita para mergear, la agregué manualmente al ./data/day.csv. El orden de los promedios observados se corresponde con el orden de los efectos de tienda definidos en el enunciado: (Santa Ana=5000, Los Cedros=Córdoba=3000, La Floresta=2000, Palermo=1000).

3.2 Intervalos de confianza de 'Santa Ana' (Punto 2)

Los intervalos muestran un patrón estacional: julio es el mes de mayor afluencia (media ≈ 11741.5) y enero/diciembre los de menor afluencia (media ≈ 9748.8 y 9710.1 respectivamente). El ancho de los intervalos es similar entre meses (en torno a 4100 clientes para el 95% y 5400 para el 99%). Lo que refleja que la dispersión dentro de cada mes proviene principalmente de la mezcla de años y días de la semana que contiene, más que del mes en sí.

3.3 ANOVA entre tiendas (Punto 3)

Se hizo la validación de homocedasticidad para poder aplicar el ANOVA mediante el test de Bartlett. Éste arrojó un p-valor = 0.9999, por lo que no se rechaza la hipótesis de homocedasticidad. Por lo tanto, se asume que las varianzas entre tiendas son homogéneas.

El ANOVA de un factor dio $F = 1723.4975$, con un p-valor prácticamente nulo ($< 1e-300$). Con $\alpha=0.05$, se rechaza la hipótesis nula y se acepta que las medias de clientes diarios no son iguales entre las cinco tiendas.

3.4 Contraste entre extremos (Punto 4)

La tienda de mayor promedio observado es 'Santa Ana' (10716.5 clientes/día) y la de menor promedio es 'Palermo' (6718.3 clientes/día). La diferencia observada es de 3998.2 clientes/día, con un estadístico $z = 79.20$ y un p-valor prácticamente nulo. Con $\alpha=0.05$, se rechaza la hipótesis nula: la diferencia es significativamente distinta de cero.

Ambas tiendas son, coincidentemente, las de mayor y menor efecto teórico definido en el enunciado (Santa Ana=5000, Palermo=1000).

4. ANÁLISIS Y CONCLUSIONES

La simulación reproduce fielmente el modelo aditivo planteado en el enunciado debido a que el orden de los promedios por tienda replica el orden de los efectos de tienda. A su vez, el rango de lambda observado coincide con el rango teórico esperado.

Los intervalos de confianza mensuales de 'Santa Ana' confirman la estacionalidad impuesta en la simulación. Con pico en julio, valles en enero y diciembre. Su ancho relativamente estable entre meses indica que la variabilidad diaria dentro de un mes depende más de la combinación de años y días de la semana que del mes calendario en sí.

El ANOVA, con sus supuestos verificados, rechaza con claridad la hipótesis de igualdad de medias entre las cinco tiendas. Es decir, existe evidencia estadística fuerte de que al menos una tienda difiere de las demás en afluencia de clientes.

El contraste entre los extremos confirma que 'Santa Ana' recibe significativamente más clientes que 'Palermo', con una diferencia de casi 4000 clientes/día. Que ambas tiendas coincidan exactamente con las de mayor y menor efecto teórico también sirve como validación de que el procedimiento de análisis recupera correctamente los parámetros usados para generar los datos.

En conclusión, la recomendación operativa para Don Francisco sería que priorice a 'Santa Ana' porque es la tienda que más clientes recibe y dirija más atención a la tienda 'Palermo'. Ya que recibe sistemáticamente la menor cantidad de clientes de las cinco tiendas, con una diferencia estadísticamente significativa respecto de la de mejor desempeño.